

基于 BMI 分组的 NIPT 检测时点优化与胎儿异常判定模型

摘要

无创产前检测 (NIPT) 作为检测胎儿染色体异常的重要手段, 其准确性显著受孕周和 BMI 等因素影响。若检测时点选择不当, 不仅会增加检测失败率, 还可能缩短临床干预窗口, 带来潜在风险。本文基于 NIPT 数据, 围绕多变量相关性分析, BMI 分组与误差敏感性分析, 检测时点优化与胎儿异常判定展开建模研究, 目标是实现分群合理、时点科学、结果稳健的个体化检测方案。

针对问题一, 为分析 Y 染色体浓度与孕周、BMI 等变量的相关特性, 本文采用 **Pearson** 与 **Spearman** 相关系数并建立**多项式回归模型**, 通过显著性检验证实 BMI 与孕周对浓度均存在非线性影响, 为后续分组提供量化依据。

针对问题二, 本文以 BMI 为主要分组指标, 构建风险最小化优化模型, 并设定置信水平 $\alpha=95\%$ 的约束条件。再通过枚举分组数与**动态规划**求解最优分界点, 最终得到 BMI 四分组方案为[20.0-25.5], [25.5-31.0], [31.0-36.5], [36.5-42.0], 并确定各组对应的最优检测时点分别为 12.1 周、10.2 周、12.0 周与 25.0 周。进一步采用**蒙特卡洛模拟**评估检测误差对结果的敏感性, 发现轻度肥胖组假阴性率最高, 提示在该组应适度延后检测时点以提升稳健性, 从而实现风险与时效的平衡。

针对问题三, 在 BMI 分组的基础上进一步引入身高、体重、年龄等多因素, 建立 **LightGBM** 浓度预测模型, 并结合**回归决策树**实现自适应分组。在置信水平约束下, 将研究对象划分为 4 个组别, 并以各组的平均达标孕周作为匹配依据确定原定检测时点。在分组与风险分级的基础上, 结合样本量加权计算总体风险, 确定最优时点, 最终使总体潜在风险由单因子分组的 1.3110 降至 0.8572, 平均最佳检测孕周约 16.5 周。其中, 风险组呈现出风险等级越高, 检测越延后的规律, 验证了多因素分组在兼顾个体差异与总体稳健性方面的优势。

针对问题四, 本文采用 **LightGBM** 高灵敏筛选与逻辑回归可解释性的**两阶段策略**, 构建胎儿染色体异常判定模型。并通过 SMOTE 平衡异常样本, 提取出 GC 含量、X 染色体浓度等关键特征, 最终实现 $AUC \approx 0.85$ 、异常类召回率 ≈ 0.80 的判定结果, 有效提升早期风险预警能力。

最后, 本文对模型进行了客观的评价并给予了一定的改进方法, 望为类似的医学检测时序优化与临床风险评估问题提供了可推广的数学建模框架。

关键词: NIPT 时点检测优化, 多项式回归模型, LightGBM 模型, 回归决策树, 逻辑回归,

一、问题重述

1.1 问题背景

无创产前检测（NIPT）通过采集孕妇外周血中的胎儿游离 DNA，并利用高通量测序技术对胎儿常见染色体非整倍体异常进行筛查，具有无创、安全等特点。该技术自卢煜明教授于 1997 年在母体血浆中发现胎儿游离 DNA 以来^[1]，已成为产前筛查的一项重要突破。NIPT 的准确性很大程度上取决于孕妇血液中胎儿游离 DNA 的浓度，而该浓度受到孕妇年龄、孕周及体重指数（BMI）等多种因素的调控^[5]。从临床实践表明，检测时孕周需控制在 10 至 25 周之间，男胎 Y 染色体浓度应不低于 4%，女胎 X 染色体浓度也需处于正常参考范围内，否则可能影响诊断结果的可靠性。

目前而言，如果针对高 BMI 等特殊人群，采取统一的检测时间窗口，容易因为个体差异导致胎儿 DNA 浓度不足，进而增加检测失败或结果误判的风险。所以，系统分析影响胎儿 DNA 浓度的关键因素，建立科学的分群检测时间规划，对提高 NIPT 在真实世界中的适用性和准确性具有重要意义。本研究基于某地区以高 BMI 为主体的人群 NIPT 数据，拟通过数学建模方法优化不同孕妇亚群的检测时机，为提升临床检测成功率提供依据

1.2 问题要求

问题 1 分析 Y 染色体浓度与孕周、BMI 等变量的相关性，建立数学模型并检验显著性

问题 2 以 BMI 为主要分类指标，对男胎孕妇进行合理分组，确定各分组最佳 NIPT 检测时点（Y 染色体浓度首次 $\geq 4\%$ ），以最小化潜在风险，并分析检测误差的影响

问题 3 引入年龄、体重、检测误差与达标比例等多因素，优化 BMI 分组并确定最佳检测时点，实现风险控制最优化

问题 4 针对女胎胎儿，依据 13、18 和 21 号染色体非整倍体检测结果，结合 X 染色体 Z 值、GC 含量、读段数及相关比例、BMI 等特征，构建女胎染色体异常判定模型

二、问题分析

2.1 问题一的分析

针对问题一，本文对数据集进行了清洗与整理，剔除了无效及异常样本，以确保数据有效性，为后续的分析奠定基础。随后，基于孕周、BMI 等关键维度出发进行可视化探索，初步把握变量间的关联模式。分析得出各变量并非完全独立，后进一步通过相关性热力图直观呈现变量间关系，并分别采用 Pearson 和

Spearman 相关系数进行量化分析。结果拒绝了变量间为纯线性关系的假定，尤其表明 BMI 和孕周与 Y 染色体浓度之间存在非线性关联趋势。因此，本研究选用多项式回归模型以更好地拟合变量间复杂关系，基于最小二乘法完成参数估计，最终通过假设检验（p 值）与拟合优度（ R^2 ）等指标对模型的有效性和显著性进行检验。

2.2 问题二的分析

针对问题二，为使孕妇可能面临的潜在风险最小化，基于第一问相关指标的研究，本文将其转换为模型的优化问题，即定义潜在分段风险函数 W_t 。为保证检测时间应具有及时性及准确性，本文将孕妇按 BMI 分为 K 组，生成 $B_1, B_2 \dots B_k$ 等 k-1 个分割点，并将对应 K 组的各组的最佳 NIPT 时点设置为 $T_1, T_2 \dots T_k$ ，并对检验误差进行蒙特卡洛模拟灵敏度分析，以分析特定 BMI 分组的孕妇群体人体内 Y 染色体浓度检测误差对预测的影响，更好地平衡时间成本。

2.3 问题三的分析

针对问题三，本文注意到在求解问题二时，以 BMI 为主要依据进行孕妇分组，并通过设定置信水平 α 的达标时点最小化孕妇平均潜在风险的模型假设，其理论上可以给出每组的 BMI 区间和最佳 NIPT 时点以降低孕妇可能的平均潜在风险。然而，以临床实际需求来看，男胎 Y 染色体浓度达标时间还受多种因素如身高、体重、年龄等的影响，若以单一的 BMI 一维切分，易导致能达到模型设定的置信水平的群体系统性减少，模型在应用上将具有一定局限性。因此，本文在对求解问题三时对原有模型进行改进，将以一维划转换至多个生理指标的综合分组，在预测 Y 染色体浓度时，构建 LightGBM 预测和决策树分组的多因素 NIPT 时点优化模型，通过合并数据项降低多重共线性以及多维度构建分组规则，应对数据中未达标孕妇比例极低的不平衡问题，建造更稳定的模型，更稳健地降低孕妇的潜在风险。

2.4 问题四的分析

针对问题四，根据前面问题的研究，判定构建高精度女胎染色体异常为典型有监督二元分类问题。解决的核心目标为，基于染色体的非整倍体列提供的“正常”与“异常”两类标签，实现对女胎染色体状态的精准分类。需要注意的是，对比前问优化时点的解答视角，该问需在更复杂的生物信息中寻找较稳定分类依据。本文建模主要围绕以下三个问题，一，孕周、Z 值、BMI 等生物学指标的非线性关系及交互作用捕捉难度大。二，染色体非整倍体异常样本极少，样本极端不平衡，若不针对性处理，模型易偏向预测“正常”类别，造成异常样本召回率偏低，从而导致漏诊风险远高于误报，产生巨大时间成本，使研究的临床实用性大大降低。三，研究方法需具备一定可解释性，出来的结论需能说明关键指标组合如何导致异常判断。为解决以上问题，本文将尝试采用 LightGBM 以自动学习复杂模式来最大化异常样本召回率，确保一定面积覆盖异常样本；运用 SMOTE 过采样方法，生成虚拟少数类样本，以缓解类别不平衡问

题；第二阶段模型会将第一阶段模型输出的特征组值导入逻辑回归模型，以提炼分层化的临床决策规则，最终形成兼顾高精度与可解释性的完整判定方法。

三、模型假设

四、符号说明

符号	含义说明
C_y	男胎 Y 染色体浓度
t	孕周
BMI	孕妇身体质量指数
GC	基因组 GC 含量
n	样本数量
T_k	第 k 组的最佳检测时点
$f(\theta)$	目标优化函数
$L(X_M, \theta_M)$	第 M 组的损失函数 (X_M 为特征数据, θ_M 为待优化参数)
θ	模型全局优化参数
R	风险值
W_1, W_2, W_3	早/中/晚孕期风险权重 (满足 $W_1 < W_2 < W_3$)

五、问题一模型的建立与求解

5.1 问题分析与数据预处理

5.1.1 问题核心与临床背景

NIPT 检测中，男胎 Y 染色体浓度（记为 C_y ）是否达到 4% 的阈值直接关系到检测结果的准确性。临床观察表明， C_y 受到孕妇孕周和 BMI 的显著影响：随着孕周增加，胎儿游离 DNA 在母血中的比例通常逐渐上升；而孕妇 BMI 偏高则可能稀释胎儿 DNA 的相对含量，延缓 C_y 达到检测要求的时间。综上，问题 1 的重点在于建立 C_y 与孕周、BMI 之间的定量关系模型，识别其间可能存在的线性或非线性关联，并对该关系进行显著性检验。这一模型的建立将为后续不同 BMI 人群分组及最佳检测时点的确定提供理论依据。

5.1.2 数据预处理流程

为保证建模数据的质量与合理性，本研究对原始数据进行了系统预处理。首先将文本格式的孕周信息统一转换为数值型周数，保留小数点后一位以提高后续分析的精度。随后针对数据中存在缺失或记录不全的样本予以剔除，并对重复检测记录进行去重处理，确保每条数据独立有效。

在此基础上，依据临床共识与数据质量要求，对关键变量设置了合理的数据范围：BMI 限定于 18.5 - 50 之间，孕妇年龄控制在 18 - 55 岁，GC 含量区间设定为 0.35 - 0.6，以排除极端测序质量异常样本。同时，将孕周数据严格限制在 12 - 20 周范围内，该区间反映了 NIPT 检测实践中具有代表性的时间窗口。通过上述步骤，获得了清洁、可靠的数据集，为后续建模分析奠定基础。

5.2 变量相关性分析：探索潜在关联规律

在构建回归模型前，需通过相关性分析初步判断 C_y 与孕周（week）、BMI 的关联形态（线性/单调非线性），为后续模型结构选择提供依据。考虑到数据量较为庞大且维度较多，利用 Python 完成该问题的核心概念年龄、身体质量指数（BMI）、Y 染色体浓度以及检测时的孕周指标的分布特征。分析结果的可视化页面如下：




图 1 孕妇年龄、BMI、Y 染色体浓度及检测孕周分布柱形图

图 1 是各个指标的分布特征，研究对象年龄主要集中在 25 - 30 岁左右，BMI 呈现中间高两端低的分布态势，Y 染色体浓度主要集中在 0.05 - 0.10 附近，检测孕周呈现多峰特点。但单变量的分布仅能反映各指标自身的频数分布情况，无法体现变量间相互关联的程度与方向。于是，本文绘制相关性热力图，以更好地可视化多个变量之间的相关系数，进而直观展示年龄、BMI、Y 染色体浓度、检测孕周等变量之间的相关程度，相关性热力图页面如下：




图 2 孕妇相关变量相关性热力图

观察图 2，该图的颜色条从下到上，颜色从蓝色渐变到红色，对应着相关性系数从 -1.0 到 1.0 的范围；在明确本研究的变量后，为探究这些变量之间的内在关联，我们采用相关性分析方法，通过颜色的深浅直观呈现各变量间的相关性程度。显然，变量自身的相关性是最强的，其次就是孕周和 BMI 蓝色较浅，说明二者具有一定的相关性。

5.2.1 相关性指标选择与原理

为了进一步探究各变量间的关联，基于相关性热力图呈现的关联情况，我们决定采用 Pearson 相关系数和 Spearman 相关系数来量化分析变量间的线性相关程度，以此得到更精准的相关性结果，从而补充热力图所展示的表层关联信息，更深入地理解变量彼此之间线性相关的强弱与方向。

Pearson 相关系数：衡量变量间线性关系强度，公式为：

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}}$$

采用 t 检验对相关系数 r_{xy} 进行显著性检验 ($H_0: r_{xy}=0$)，若检验 p 值小于 0.05，则拒绝原假设，表明两变量间线性相关关系显著。

Spearman 等级相关系数：衡量变量间单调关系强度（不受非线性影响），公式为：

$$\rho_{xy} = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

其中 d_i 为每对观测值在孕周（或 BMI）和 C_y 上的等级差。同样通过 t 检验验证显著性，若 ρ 显著而 r_{xy} 不显著，说明关联为单调非线性。

5.2.2 相关性分析结果与启示

利用 Python 求解 C_y 与孕妇 BMI 及孕周的 **Pearson** 和 **Spearman** 相关系数如下表所示：

表 1 Y 染色体浓度与孕妇 BMI、检测孕周的相关性分析表

Y 染色体浓度 vs 孕妇 BMI	
Pearson	-0.190 (p=0.000)
Spearman	-0.145 (p=0.000)
Y 染色体浓度 vs 孕周	
Pearson	0.028 (p=0.439)
Spearman	0.037 (p=0.312)

表 1 表明，Y 染色体浓度与 BMI 之间存在负相关关系，然而，线性相关系数绝对值较低 ($|r| < 0.2$)，说明变量间关系可能并非简单的线性模式，为进一步探索 BMI 与 Y 染色体浓度之间可能存在的非线性关系，并提高模型预测能力，本文引入更灵活的建模方法。

5.3 回归模型的构建与演进：从线性到多项式

为逐步优化模型对非线性关系的拟合能力，采用“线性回归→含二次项的多项式回归→含交互项的多项式回归”的演进路径，每一步均基于前序模型的不足进行改进，使模型既符合数据特征，又具备临床解释性。

5.3.1 简单线性回归模型（基础模型）

首先构建仅含线性项的多元线性回归模型，作为基准模型，公式为：

$$C_y = \beta_0 + \beta_1 \cdot week + \beta_2 \cdot BMI + \beta_3 \cdot age + \epsilon$$

在简单线性回归建模时，我们用线性关系刻画自变量（如孕周、BMI 等）与 Y 染色体浓度的关联，但线性回归的有效应用以一系列假设为前提，**残差的特征是验证这些假设是否成立的核心依据**。残差是观测值与模型预测值的差值，若残差呈现随预测值增大持续递增或递减的曲线趋势，则说明简单线性模型可能无法充分抓住变量间的真实关系。所以，为了检验简单线性回归模型的假设合理性、判断拟合效果，必须开展残差分析。通过绘制残差图，能直观看到残差的分布情况和变化趋势。残差图如下：




图 3 残差与孕周小数的散点及趋势图

图 3 显示，残差与孕周的散点图呈“先负后正再负”的二次趋势，违反线性回归基本假设，说明未捕捉孕周的非线性效应。

5.3.2 含二次项的多项式回归模型的选择与建立

在初步分析了孕妇群体的年龄、BMI、Y 染色体浓度和检测孕周这些单变量的分布特征，也探索了变量之间的相关性后，研究接下来重点关注“孕周”和“BMI”对 Y 染色体浓度的联合影响。从生理角度想，孕周是孕期时间的核心指标，BMI 又和孕妇的身体状况息息相关，这两个因素很可能一起作用，影响 Y 染色体相关的生物信号，比如胎儿来源游离 DNA 的检测浓度。

为了弄清楚这种“联合影响”是否存在，以及具体是怎么起作用的，就需要构建包含高次项和交互项的多项式回归模型。本文将孕周的高次项、BMI 的高次项，还有孕周和 BMI 的交互项等关键数据放进模型里，以更好地把握变量之间非简单线性的关联规律。同时，基于之前单变量分析和简单相关性分析，绘制以下“三维曲面图”，把这种交互效应直观地展示出来，如下图：




图 4 孕周与 BMI 对 Y 染色体浓度交互效应的三维曲面图

图 4 所示，当孕周和 BMI 一起变化时，Y 染色体浓度会呈现出不是平面，而是带有曲率的变化情况。具体来看，孕周对 Y 染色体浓度的作用，会随 BMI 变化而不同；反过来，BMI 的影响也会因孕周阶段不一样而改变。其证明了“孕周×BMI”对 Y 染色体浓度的非线性交互机制，为之后适合分析非线性弯曲趋势的多项式回归模型选择提供有力依据，也为之前研究的做出进一步延伸和探索。

综上所述，此图直观地支持了用含高次项与交互项的多项式回归模型来分析三者关系的选择。

根据相关性分析得出的“孕周与 C_y 呈非线性单调正相关”“ BMI 与 C_y 可能先正后负”两结论，我们在基础模型里加入孕周二次项（ $week^2$ ）和 BMI 二次项（ BMI^2 ）来捕捉非线性效应，模型公式为：

$$C_y = \beta_0 + \beta_1 \cdot week + \beta_2 \cdot BMI + \beta_3 \cdot age + \beta_4 \cdot week^2 + \beta_5 \cdot BMI^2 + \epsilon$$

在构建含二次项的多项式回归模型时，我们通过系数符号来判断变量对 C_y 的非线性影响方向，即若 $\beta_4 < 0$ ，则孕周对 C_y 的边际效应随孕周增大而减小，符合“孕早期浓度快速上升、孕中期后增速放缓”的临床规律；若 $\beta_5 < 0$ ，则 BMI 对 C_y 的边际效应随 C_y 增大由正转负，印证“ BMI 过高稀释胎儿游离 DNA”的机制。

采用最小二乘方法对模型参数进行估计，并基于样本数据完成拟合。通过对样本数据的参数估计，最终得到的 C_y 预测方程为：

$$Y = -0.3595 + 0.0279 \times week + 0.0169 \times BMI - 0.0009 \times age - 0.0009 \times week^2 - 0.0003 \times BMI^2$$

通过对该多项式模型的参数估计与统计检验，本文更细致地解析了孕周、 BMI 对 C_y 的非线性作用模式，弥补了简单线性回归无法刻画复杂关联的不足，为阐释胎儿游离 DNA 浓度的变化规律提供更贴合实际的统计支撑。

5.3.3 模型的显著性检验

综上所述，为检验所建立的多项式回归模型是否显著，我们对于模型整体及其各项系数进行了系统的假设检验。

表 2 孕妇 Y 染色体浓度影响因素的多元回归系数表

	Coef	Std err	t	P> t
Const	-0.3595	0.121	-2.975	0.003
孕周	0.0279	0.008	3.296	0.001
BMI	0.0169	0.005	3.276	0.001
年龄	-0.0009	0.000	-2.984	0.003
孕周^2	-0.0009	0.000	-4.209	0.000
BMI^2	-0.0003	6.65e-05	-4.344	0.000
孕周 × BMI	-8.533e-08	0.000	-0.001	1.000

如表 2 所示，除了交互项“孕周×BMI”的 p 值为 1.000，并未通过显著性检验外，其余变量均表现出高度的统计显著性（p 值均小于 0.01），说明它们对 Y 染色体浓度具有显著影响。而常数项、孕周、BMI、年龄及二者的二次项系数其 p 值都远远小于 0.05 的显著性水平，孕周二次项系数为负（-0.0009, p=0.000）尤为显著，这一数据表明，孕周对 Y 染色体浓度的边际效应会随孕期推进而递减；而 BMI 二次项系数同样为负（-0.0003, p=0.000），可以支持 BMI 与浓度之间存在倒 U 型关系的假设。鉴于表 2 显示的交互项完全不显著，因此，在后续的研究中，我们将这一项从最终模型中剔除。

尽管模型的确定系数 (R^2) 为 0.087, 但考虑到生物医学具有数据复杂性和个体差异性^[3], 该模型在理论上已经能够将关键变量的变化趋势捕捉出来, 为后续的研究分析提供了一定所需的可靠量化依据。

六、问题二模型的建立与求解

6.1 男胎孕妇 BMI 分组与最佳 NIPT 时点确定

6.1.1 基于 BMI 分组的 NIPT 检测时点优化模型研究

(一) 数据预处理准备

针对问题二, 本文通过筛选出所有男胎样本, 并基于临床可行性及计算模型拟合度, 筛选出 12-20 周的孕周, 符号为 A_t 。同时, 因高通量测序过程存在显著的 GC 偏好性偏差, 极端 GC 含量的片段其测序深度会被系统性地低估, 为保证模型的准确性, 本文剔除了 GC 含量低于 0.35 或高于 0.6 的测序片段, 以有效减少技术性噪音。然后, 对数据进行清洗。将数据中的孕周转化为同单位的小数并处理以及过滤缺失值, 并对数据进行重复检测, 将同一孕妇多次的检测记录视作同一时间序列, 以减少对预测的干扰。孕妇代码和检测日期分组均取均值, 从而简化模型的设立。

(二) 模型选择

与优化模型相比, 本文没有采用聚类模型的原因是其常常基于距离或相似性度量进行划分, 其结果依赖算法设定与参数选择, 缺乏医学与统计学上的明确解释力。而本研究使用的“基于 BMI 分组的优化模型”, 使用 BMI 作为妊娠风险的重要指标, 可以高效率地区分孕妇群体差异, 可使分组后样本方差下降, 增强模型的稳健性与解释力。本文通过构建优化函数, 公式如下

$$\min f(\theta) = \sum_{M=1}^M L(X_M, \theta_M)$$

其中, M 为样本数量, $L(X_M, \theta_M)$ 为损失函数。基于此, 可以一定程度地保证分层建模的合理性。综上所述, 我们选择 BMI 分组优化模型进行研究。

(三) 模型假设及建立

本文根据题目背景, 定义“男胎 Y 染色体浓度达到或高于 4%”为 NIPT 基本准确的条件。基于问题一的研究, 使用染色体浓度与孕周数和 BMI 的关系模型, 将其表示为 $C = f(a, b)$, 其中 a 是孕周, b 是 BMI。设每一位男胎孕妇 (样本 i) 其 BMI 为 b_i , 再利用模型 $C = f(a, b_i)$ 来预测其 Y 染色体浓度随孕周 a 变

化的曲线，然后，通过求解不等式 $f(a, b_i) \geq 4\%$ ，得到满足条件的最小孕周 a ，记为该孕妇的理论最早达标孕周 A_i^* 。

参考问题背景，考虑临床实践与检测学特性的共同影响，本文将孕周划分为早期（ ≤ 12 周）、中期（13 - 27 周）和晚期（ ≥ 28 周）。这样的划分参考了产科常用的三孕期分界及 NIPT 检测中过早检测易提高无响应和假阴风险的惯性，着眼于 NIPT 临床意义，即检测本身是否达标，还取决于它能否在确诊性产前诊断的时间窗内提供可操作的信息。而根据孕妇的确诊性检查：(CVS) 主要在 10 - 13 周进行，羊膜穿刺则集中在 15 - 20 周^[2]，若能在早期完成筛查，即可与后续的检查一脉相通，给予医务人员即生产当事人更多的决策时间。以上，为了使模型更具有普适性，我们沿用了问题背景对孕周的划分，并依此建立了风险函数 W_t 。

$$W_t = \begin{cases} W_1, t \leq 12 \\ W_2, 13 \leq t \leq 27 \\ W_3, t \geq 28 \end{cases}$$

其中 $W_1 < W_2 < W_3$ 是代表低，高，极高风险的常数值。

假设将孕妇按 BMI 分为 K 组，生成 $B_1, B_2 \dots B_k$ 等 k-1 个分割点，建立函数，使所有孕妇的平均潜在风险最小化并将对应 K 组的各组的最佳 NIPT 时点设置为 $T_1, T_2 \dots T_k$ ，风险最小化公式为：

$$\min \sum_{K=1}^K \frac{N_K}{N} R(T_K)$$

其中 N 为男胎孕妇总数，K 为第 K 组有 N_K 位孕妇。

后给予模型约束条件，设定置信水平 $\alpha = 95\%$ ，要求在时点 T_K ，第 k 组中至少有 α 比例的孕妇的预测 Y 染色体浓度为 $C \geq 4\%$ 。对于 BMI 在 $[B_{k-1}, B_k)$ 内，其检测的时间点 T_k 必须满足

$$\frac{|\{i \mid \text{孕妇 } i \in \text{组 } k \text{ 且 } f(T_k, b_i) \geq 4\% \}|}{N_k} \geq \alpha$$

其中 $|\cdot|$ 表示集合中元素的数量。

因此，对于每个已经确定的分组 K，其最佳检测时点 T_K 应是满足上述准确性约束的最早时间点。即：

$$T_k = \min \left\{ t \mid \frac{|\{i \mid \text{孕妇 } i \in \text{组 } k \text{ 且 } f(t, b_i) \geq 4\% \}|}{N_k} \geq \alpha \right\}$$

6.1.2 模型求解与结果分析

我们首先确定分组数 K ，依据题目的参考分组与数据的分布，将数据范围初步确定在[20,42]之间，逐步从 $K=2, 3, 4, 5, 6$ 进行尝试。通过计算每一个 K 值对应的总风险值，选择总风险值为最小的 K 值作为模型的最优分组数。

后续，我们的问题转化为寻找最佳的 BMI 分割点 $(B_1, \dots, B_{K-1})$ ，以最小化以下目标函数：

$$\min_{B_1, \dots, B_{K-1}} \sum_{k=1}^K \frac{N_k}{N} R(T_k(B_{k-1}, B_k))$$

其中 T_k 的值由上述约束条件隐形确定。

将序列分割为 K 个阶段，后在一阶段中根据已分割的序列特征和分割位置确定下一个阶段状态，通过不断求问题的最优解，逐步求出 K 值和最低风险的最优解。完成分组之后，我们将进行数据分析及利用映射关系推导相应的 BMI 分组区间。

如表 3，我们计算出最小风险值为分组数 $K=4$ ，其总体风险最小。所以在此模型中，我们选择将 BMI 分为四组，分割点为[25.5,31.0,36.5]。

分组数	总体风险	分割点
2	3.3937	[31.0]
3	1.6903	[27.3,34.7]
4	1.3110	[25.5,31.0,36.5]
5	2.3504	[24.4,28.8,33.2,37.6]
6	1.6155	[23.7,27.3,31.0,34.7,38.3]

表 3 分组数与总体风险对应表

同时，在本研究中，我们通过作出总体风险值与分组数 K 的变化趋势图，直观地看出不同的分组对风险值的影响。且基于上图的分析，可以确定当 $K=4$ 时（即分组数为 4 时），对应的总体风险值最低；当分组数低于 4 组时，总体风险值随着分组数的增多而降低；但当分组数高于 4 时，总体风险值反而出现反弹，推测这是由分组数量过多而导致的管理难度增加、资源过于分散等负面现象；针对以上研究结果，我们在本文中将 BMI 分组设置为 4 组，可以有效避免由于分组较少而导致的风险过高，同时也规避由于分组较多导致的其他问题。




图 5 总体风险随分组数 K 变化趋势

在理想条件下，本文基于孕妇生理特征的分布计算最优时间节点，将最早达标孕周 A_i （孕妇 Y 染色体浓度首次达到或者阈值超过 4%为最早孕周）视为模型的重要指标，这一指标的形成主要受到胎儿发育速率、母体代谢特征以及检测灵敏度等多因素综合影响。考虑以上因素，本文进行函数计算得到，如表 4 所示结论

组别	BMI 范围	样本数	权重	最优检测时点	风险值
1	[20.0, 25.5]	3	0.004	12.1	较高
2	[25.5, 31.0]	303	0.398	10.2	低
3	[31.0, 36.5]	411	0.539	12.0	低
4	[36.5, 42.0]	45	0.059	25.0	高

表 4 最佳 BMI 分组方案

据通过考虑不同 BMI 区间的孕妇生理差异特征，本文将 BMI 分为“正常偏高”、“轻度肥胖”、“中度肥胖”、“重度肥胖”四组，得出每一组的推荐 NIPT 检测时点，见图 4。并绘制最优 BMI 分组与检测时点方案图，为后续每一组进行个性化检测奠定了基础。图中黑色的水平线为每一组的推荐 NIPT 检测时点。基于不同组别对应的检测孕周，可得 BMI 浓度会随着检测孕周波动。由于在“轻度肥胖”组的 BMI 下，样本浓度上升较快，相关激素分泌较高，早期检测即可达标，所以这一组检测时点最早；而在“重度肥胖”组的高 BMI 下，浓度变化波动大且较低，需要更晚检测以保证浓度够稳定且够高。

图表中的浅色填充区展示了组内大部分样本在预计检测时点下的浓度分布。所有浅色区域均位于达标阈值 4% 的上方，这表明在推荐点进行检测时，组内样本浓度基本能达标。基于此结论，本文的优化模型的临床可靠性得到充分证明且

具有说服力。与此同时，图表中对各个区域的分块也表明了组内的个体差异，即在组内的个体存在轻微的波动并不影响整体的达标。




图 6 最优 BMI 分组与检测时点方案图

综上，据表 4 与图 6，本文得出每组的 BMI 区间和最佳 NIPT 时点。且图 6 可较为直观全面地呈现如何分组以及何时检测及其结果的可靠性的检测方案，为孕妇的健康提供了安全、科学指导方案。

6.1.3 分析误差对结果的影响

在孕妇检测时点基于 BMI 分组方案的研究中，误差可能会对最终的分组结果、风险评估以及最优检测时点产生难以忽略的影响。因此我们要深入分析误差。

误差可能由实验操作、样本保存不当、设备差异导致 Y 染色体测量浓度与真实浓度存在差异，假设真实浓度为 C_{true} ，测量浓度为 $C_{measured}$ ，二者之间存在误差项 ϵ ，

$$\text{即 } C_{measured} = C_{true} + \epsilon。$$

其他造成误差的原因也有可能是孕周推算无法避免胎儿发育速率不同导致的胎儿实际发育情况不同、超声测量不够准确、BMI 测量误差等。这些误差会影响我们对孕妇达标的判断，当真实浓度 $f(t,b) \geq 4\%$ 时，出现负的误差 ϵ ，会导致测量值低于 4%，继而造成假阴性，导致我们误以为孕妇未达标，需要将检测时点推迟，反之出现了正的结果可能造成假阳性。

因此，为了量化检测误差对结果的一些，我们选择蒙特卡洛模拟方法：即在已确定的最佳时点 T_k 上，对第 k 组的每个孕妇，设其预测浓度为 $f(T_k, b_i)$ 。为这个值加上一个随机误差 ϵ ，进行 1000 次模拟。

得到的结果如下表所示：

分组	假阴性率	假阳性率	真实达标率
正常偏高	2.53%	0.00%	100.00%
轻度肥胖	35.96%	0.00%	100.00%
中度肥胖	9.83%	2.59%	91.00%
重度肥胖	0.00%	0.00%	0.00%

表 5 蒙特卡洛模拟结果

1) 结果分析

在不同的 BMI 分组中，检测误差对达标情况判断的影响呈现显著差异。正常偏高组的数据说明在该组中检测误差对总体达标判断的影响较小，仅造成少量孕妇被误判为未达标。相比之下，轻度肥胖组的假阴性率高达 35.96%，表明该组中存在大量实际已达标的孕妇因误差被错误归类，这一情况可能对 NIPT 时点带来干扰，导致部分孕妇的检测时间被延迟。中度肥胖的检测误差对该组的判定带来一定不确定性，使得检测策略的制定面临假阴性与假阳性同时存在的问题。而在重度肥胖组中，尽管假阴性与假阳性率均为 0.00%，但真实达标率为 0.00%，推测可能是该组孕妇的生理特性与其他组别存在本质差异，从而导致模拟出现异常，这一结果仍需结合更多数据进行深入分析。

2) 对检测时点的影响及应对策略

通过构建蒙特卡洛模拟模型，本文分析出检测误差对检测时点选择存在重要影响。如果模拟结果中假阴性率较高，则表明原定检测时点 T_k 可能过于超前，需适度延后以抵消误差干扰，从而保障绝大多数孕妇在实际检测中能够稳定达到浓度要求。因此，在确定最终推荐时点时，应引入误差修正机制，依据模拟所得假阴性率与假阳性率动态调整各组检测时间，以提高实际达标的置信水平，增强检测策略的稳健性与适用性。

七、问题三模型的建立与求解

7.1.1 数据预处理

本文根据 Y 染色体浓度及 Z 值是否存在，判定样本对象性别，以剔除女胎样本，保证研究对象一致。其次，删除末次月经时间字段，统一以检测记录中的孕周为时间变量，避免因回忆误差造成系统性偏差。检查 BMI、身高、体重、年龄等关键变量，对缺失值和异常值进行处理，若缺失比例较小则直接剔除，若在

同一孕妇的多次检测中存在部分缺失，则使用邻近检测值进行填补。对于存在多次检测记录的孕妇，采取与问题二同样的做法，按孕周顺序排列，构建其 Y 染色体浓度随孕周变化的时间序列，保证模型训练时信息完整。最后，将数据集随机划分为训练集和测试集，保持总体分布一致，以便后续模型训练与稳健性验证。

7.1.2 模型假设

本文后续建模基于以下假设前要。一，检测误差近似服从均值为零的正态分布，该分布由模型残差刻画且波动幅度较小。二，风险函数采用早中晚三阶段分段形式能够近似反映临床潜在风险水平，忽略细微非线性差异。

7.1.3 模型建立

本文采用 LightGBM 建立 Y 染色体浓度预测模型，结合回归决策树对孕妇进行多因素分组^[6]。同时在考虑检测误差和置信水平的约束下确定各组最佳检测时点，以最小化整体潜在风险。以下为 LightGBM 浓度预测模型公式

$$\hat{C}_i(t) = g(t, h_i, w_i, a_i)$$

其中， h_i 为身高， w_i 为体重， a_i 为年龄。此处忽略 BMI，计算时直接引入原始数据，以降低多重共线性，由模型自动学习复杂交互替代。

本文建造达标概率模型。其实际浓度的公式为：

$$C_i^{\text{true}}(t) = \hat{C}_i(t) + \varepsilon, \quad \varepsilon \sim N(0, \sigma_e^2).$$

其孕妇 i 在孕周 t 达标 ($\geq 4\%$) 的概率公式为：

$$P_i(t) = \Pr(C_i^{\text{true}}(t) \geq 0.04) = 1 - \Phi\left(\frac{0.04 - \hat{C}_i(t)}{\sigma_e}\right)$$

其中， $\Phi(\cdot)$ 为标准正态分布 CDF。

基于第二问的求解概念，采用 LightGBM 重新定义“最早达标孕周”。公式为：

$$A_i^* = \min\{t: \hat{C}_i(t) \geq 0.04\}$$

此值作为分组过程中的目标变量，能够为我们反映出个体在满足达标要求时所面临的难度差异。

往后，本文将视角从单一个体转向群体层面。通过选用回归决策树驱动的自适应分组策略，将个体的 A_i 设定为分组的目标变量，同时把 BMI、 h_i ， m_i ， a_i 等生理参数作为模型输入特征，借助决策树模型有效学习这些特征与 A_i 之间的关联规律。在分组操作中，决策树将在特征空间内确定最优分割节点，

进而构建层次化的分组体系。举例来说，模型会将 “BMI ≥ 32 且身高 < 160 cm” 这一在个体层面达标孕周有明显差异化的孕妇群体划入同一组别，同时也能确保组内孕妇的理论达标孕周具有较高同质化。

本文将检测误差与置信水平 α 作为约束条件，进一步搭建组别层面的最优 NIPT 时点优化模型，最终实现整体风险的降低。

对分组 K （包含样本集合 G_k ），其最佳检测时点定义为：

$$T_k = \min \left\{ t: \frac{1}{N_k} \sum_{i \in G_k} P_i(t) \geq \alpha \right\}$$

其中 $N_k = |G_k|$, $\alpha=95\%$ 为约束阈值

为达到综合优化效果，本文目的在找到由决策树确定的分组规则 B 与各组时点 T_k ，以最小化加权总体风险：

$$\min_{B, \{T_k\}} Z = \sum_{k=1}^K \frac{N_k}{N} R(T_k)$$

若考虑分组复杂度惩罚，可改写为：

$$Z = \sum_{k=1}^K \frac{N_k}{N} R(T_k) + \gamma K,$$

其中 γ 为惩罚因子，避免过度分组。

7.1.4 模型求解与结果分析

利用 **Python** 求解最佳分组如下表所示：

表 6 回归决策树模型最优参数与核心结果表

最优参数	树深度=2, $\gamma=2.0$
分组数量	4
总体风险值	0.8572
总样本数	762

首先，我们已知树深度和 γ 是 LightGBM 的关键参数，通过调整这两个因素得到了分组结果，计算总体风险值. 在此之前还需明确最佳检测时点 T_k 以及权重，代入公式计算，并且在“分组不要过多过细”和“风险尽可能低”之间平衡。

表 7 多因素影响下的合理 BMI 区间及最佳 NIPT 时点

组别	样本数	T_k (周)	风险值	平均达 标周
5	273	17.6	0.0000	16.3
3	169	15.2	0.0001	14.2
6	93	20.0	0.0000	19.5
2	227	13.3	0.0037	12.7

为了减少治疗窗口期风险，我们将研究对象划分为 4 个组别并且以各组平均达标周匹配 T_k 。如组别 2 因“平均达标周”较早，选择在 13.3 周提前检测；其中各组可按风险等级划分：

表 8 风险等级划分表

低风险组 ($T_k \leq 15.2$ 周)	组 [2]
中风险组 ($15.2 \text{ 周} < T_k \leq 17.6 \text{ 周}$)	组 [5, 3]
高风险组 ($T_k > 17.6$ 周)	组 [6]

在分组与风险分级基础上，通过已知信息得到总体风险，同时结合各组 T_k 与样本量加权，算出平均最佳检测时点。

表 9 最小总体风险及平均最佳检测时点结果分析

最小总体风险	0.8572
平均最佳检测时点	16.52 周

7.1.5 模型评价与可视化

在完成模型构建与求解后，为系统评估多因素 NIPT 时点优化模型，本文将从分类性能、阈值选择、动态达标过程及时点决策四个维度进行了综合可视化分析。

首先，我们绘制了孕周达标预测的精确率-召回率曲线（PR 曲线），该曲线能反应模型对“达标样本”的识别能力。




图 7 孕周达标预测 PR 曲线图

据图 7，AP 面积高于基线，说明模型可以顺利识别达标样本。

接下来，为了进一步了解在不同阈值下模型的性能，我们绘制了多指标阈值分析图，如图 8 所示：




图 8 不同阈值下的分类性能指标变化折线图

据图 8，得当分类阈值升高时，敏感性持续下降、特异性不断上升的趋势，直观体现了“抓对达标样本”与“不误判未达标样本”的平衡。红色虚线标注的最优阈值 0.8，是综合各指标后能让精确率、F1 分数等表现更均衡的临界点。依照以上对数据的可视化页面，可直观地把握阈值对性能的影响规律，为“孕周达标预测”选择更契合需求的分类标准提供了直观参考。

为更直观地感受不同风险群体的达标进程差异，我们选择分析各风险组随时间推移的达标概率变化。




图 9 各风险分组群体达标概率曲线与最佳检测时点图

见图 9，本文发现高风险群体的达标概率随孕周上升最快，约在 17.9 周达到目标概率；中、低风险群体达标进程相对缓慢，低风险群体最佳检测时点延迟至约 20.8 周，整体呈现“风险越高，达标速度越快、检测时点越早”的规律。

综上，为综合呈现分组风险与最佳时点的关系，我们绘制了**最佳检测时点与风险分级关系图**。




图 10 各分组最佳检测时点及平均达标孕周柱状对比图

见图 10，左图可见风险越高，最佳检测时点越早，低风险组晚于中风险组、高风险组；右图显示各风险组的最佳检测时点均晚于平均达标孕周，在达标规律基础上，为检测提供更具针对性的时间参考。

表 10 训练与测试风险参数敏感性分析

风险参数敏感性分析

$\gamma=0.5$: 训练风险=0.002617, 测试风险=0.002617, 比率=1.000
$\gamma=1.0$: 训练风险=0.000137, 测试风险=0.000137, 比率=1.000
$\gamma=1.5$: 训练风险=0.000007, 测试风险=0.000007, 比率=1.000
$\gamma=2.0$: 训练风险=0.000000, 测试风险=0.000000, 比率=1.000

见表 10，随着 γ 从 0.5 提升至 2.0，模型的训练风险与测试风险同步持续下降，直至 $\gamma=2.0$ 时均降至 0.000000，且各 γ 取值下训练风险与测试风险的比率始终保持 1.000。这既表明增大 γ 的惩罚力度能有效控制模型风险，也体现出模型在训练数据与测试数据上的性能高度一致，不存在过拟合问题，泛化稳定性较强。

八、问题四模型的建立与求解

8.1.1 数据预处理

为使保障模型训练质量与有效性，本文对女胎检测数据进行了以下预处理：进行数据清洗转换，将女胎孕妇的 21 号、18 号和 13 号染色体非整倍体（AB 列）为转为二元标签 `is_abnormal`^[4]。若 AB 列为空或无异常记录，则记为正常“0”，若 AB 列包含任一异常标识如“T13”，“T18”，“T21”，则记为异常“1”。其次，将检测孕周（J 列）由“Xw+Y”格式转换为十进制周数，公式为：

$$\text{gest week} = W + \frac{D}{7}.$$

其中 W 为整周，D 为天数。其次，移除“序号”“末次月经时间”等无关列及女胎空值 Y 染色体列。处理缺失与异常值时，数值特征缺失比例低则用中位数补全，BMI 剔除 BMI <15 或 >60 的极端值，保留 Z 值高值。因预处理后异常样本（`is_abnormal=1`）远少于正常样本，训练前对训练集用 SMOTE 算法，通过少数类样本插值生成新样本，增加少数类数量以保障模型学习异常特征。需要说明的是，为保证评估真实性，所有如 SMOTE 这类合成或平衡操作仅应用于训练集，测试集需维持标签的原始分布，不做额外处理。

为使划分的训练集和测试集中异常样本比例保持一致，本文为将数据集按 8:2 比例进行分层随机抽样，并对训练集的数值型特征统一进行 Z-score 标准化，公式如下

$$X' = \frac{X - \mu}{\sigma}$$

其中 μ 和 σ 分别为训练集特征的均值和标准差，并将其应用于测试集，以消除量纲影响。

8.1.2 模型建立

针对女胎染色体异常判定问题，本文提出了两阶段混合建模策略。阶段一，我们构建了 LightGBM 高灵敏度筛选模型，通过设置类别权重以调整参数 `scale` 增强对少数异常样本的识别能力。我们在经过 SMOTE 平衡处理的训练集上完成模型训练，并采用交叉验证方法优化超参数，将优化目标聚焦于最大化异常类别（class=1）的召回率，从而尽可能减少漏诊，其基本模型表达为

$$\hat{y}_i = \sum_{m=1}^M f_m(x_i), \quad f_m \in \mathcal{F}$$

其中， $\hat{y}_i$ 表示样本 i 的预测输出， $\mathcal{F}$ 表示所有 CART 决策树的集合， f_m 为第 m 棵树。模型训练的目标是最小化以下正则化损失函数：

$$L = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{m=1}^M \Omega(f_m),$$

其中 $l(y_i, \hat{y}_i)$ 是二分类的对数损失函数：

$$l(y_i, \hat{y}_i) = -[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)]$$

其中 $\hat{p}_i = \sigma(\hat{y}_i)$ 为 sigmoid 函数输出的概率。正则化项 $\Omega(f_m)$ 用于控制树的复杂度。在类别不平衡的情况下，LightGBM 通过在损失函数中引入类别权重，等效于在上述 $l(y_i, \hat{y}_i)$ 前增加权重系数 α_1 （异常类）与 α_0 （正常类），从而提高少数类的识别能力。

其次，建立带权重的逻辑回归可解释性模型。该模型同样在平衡后的训练集上训练，主要用于揭示各特征的线性贡献度与方向。其数学表达为：

$$\ln \frac{1 - P(Y = 1)}{P(Y = 1)} = \beta_0 + \sum_{j=1}^p \beta_j X_j$$

其中， β_j 表示特征 X_j 的回归系数。通过对系数符号与大小的分析，可以量化不同特征对异常风险（即样本被判定为异常的对数几率）的具体影响，从而为临床解释提供依据。

以上，在本文提出了两阶段混合建模策略中，LightGBM 模型将承担高性能筛查的任务，而逻辑回归模型将提供透明的特征解释。本文将在最大程度保持判定的灵敏性的同时，保持模型在实际应用中的可解释性。

8.1.3 模型求解与结果分析

利用 LightGBM、带 L1 惩罚的逻辑回归 (Lasso) 和递归特征消除 (RFE) 三种方法分别从数据中提取了 8 个、6 个、10 个特征；将三个方法所得的结果相交可以

的得到最终所选择的 4 个特征，即：['13 号染色体的 GC 含量'、'被过滤掉读段数的比例'、'体重'、'X 染色体浓度']。

经过在 SMOTE 平衡处理的训练集上完成模型的训练和评估，得到最终逻辑回归模型。在测试集上进行性能评估得到分类报告：

表 1 在测试集上模型性能评估的分类报告

类别	精确率 (Precision)	召回率 (Recall)	F1 分数 (F1-Score)	支持数 (Support)
正常(0)	0.97	0.73	0.84	162
异常(1)	0.27	0.80	0.41	20
准确率 (Accuracy)			0.74	182
宏平均(macro avg)	0.62	0.77	0.62	182
加权平均(weighted avg)	0.89	0.74	0.79	182

并且我们可以得到该模型的整体样本重要指标：

准确率	0.7418
精确率	0.2712
召回率	0.8000
F1 分数	0.8500

根据分类报告表我们可以得到正常类的精确率为 0.97 较高，误判概率较低；召回率为 0.73，意味着仅有 73% 的样本被识别为正常样本，剩余 27% 的正常样本会被误判为异常（假阳性）；由于 F1 分数的精确率为 0.84，即精确率和召回率的调和平均能较好地均衡正常类的判定精确度和覆盖完整度，可作为临床医学对正常样本判别的基础依据。

而对于异常类（即少数类），我们可以看到精确率仅为 0.27，说明被预测的异常样本中仅有 27% 为真实的异常其余 73% 的正常样本会被误判为异常（假阳性），导致这一问题的原因可能是异常样本过少，特征表述不足而产生大量误报。而召回率达到了 0.8，说明有 80% 的样本被模型成功识别，漏检率较低，由于漏检可能导致异常的胎儿错过早期干预治疗的时机，引发严重妊娠间距；所以较高的召回率具有临床使用价值，可作为孕妇早期风险预警的重要工具。

如下图 ROC 曲线是评价二分类模型即“区分正类(异常值)与负类(正常值)”的能力的重要工具，横轴为假阳性率（即正常样本被误判的概率），纵轴为真阳

性率（即召回率）。若图中实际 ROC 曲线（橙色实线）越贴合随机猜测的基准线（蓝色虚线），则模拟性能与随机猜测的结果越一致。由图可知，本模型中 ROC 曲线限制高于随机基准线，且曲线下面积 AUC 为 0.85。由于当 AUC 值越接近于 1，模型区分正常与异常样本的能力越强，我们可以得到当 AUC=0.85 时，女胎异常判定模型可以有效区分异常样本与正常样本，模型整体判别能力处于较优水平。

进一步观察图可知，当假阳性率 (FPR) 处于较低水平时，真阳性率 (TPR) 快速上升。这表明在模型正常样本误报率较低的情况下，我们对一次样本有高召回率。结合女胎异常的早期临床筛查场景，该特征可以减少医疗资源的浪费，为早期干预提供有力支持。




图 3 接收者操作特征曲线

九、模型改进

针对男胎检测时点模型，可细化“孕周-BMI-身高”三维分组规则，针对轻度肥胖组假阴性率高的问题，增设时点延后系数，中度肥胖组设达标概率预警阈值，提升稳健性。

针对女胎异常判定模型可加入 21 号染色体 Z 值特征，经 Lasso 筛选后优化区分度，同时按权重融合 LightGBM 与逻辑回归输出，平衡召回率与可解释性。

改进后模型能进一步适配高 BMI 群体特性，减少检测误差干扰，提升 NIPT 检测个性化与准确性，更贴合临床实际需求，有助于模型的推广。

十、参考文献

- [1] Lo Y M, Corbetta N, Chamberlain P F, et al. Presence of fetal DNA in maternal plasma and serum[J]. The Lancet, 1997, 350(9076): 485-487
- [2] 刘芳, 王雪燕, 漆洪波. 2021 年 RCOG 指南要点解读: 羊膜腔穿刺术和绒毛取样术 [J]. 中华围产医学杂志, 2022 (5): 385-391
- [3] 沈福民. 流行病学原理与方法 [M]. 上海医科大学出版社, 2001: 98-107
- [4] 张丽娜, 甄恩明, 乔志坤, 等. 性染色体异常的产前诊断指征及妊娠结局分析 [J]. 中国妇幼健康研究, 2020, 31 (6): 774-777
- [5] 郑芸芸, 万陕宁, 宋婷婷, 等. 8594 例孕妇无创 DNA 产前检测在胎儿染色体非整倍体疾病筛查中的临床应用 [J]. 实用妇产科杂志, 2019, 35 (1): 68-71
- [6] Liang D, Cram D S, Tan H, et al. Clinical utility of noninvasive prenatal screening for expanded chromosome disease syndromes[J]. Genetics in Medicine, 2019, 21(9): 1998-2006
- [7] 部分代码见支撑材料

十一、附录

代码摘要:

男胎数据清洗:

```
import pandas as pd
import matplotlib.pyplot as plt
plt.rcParams['font.sans-serif']=['SimHei']
plt.rcParams['axes.unicode_minus']=False
data=pd.read_csv('男胎检测数据.csv',encoding='gbk')
data['孕周_小数']=data['检测孕周'].apply(
    lambda x: round(int(x.upper().split('W')[0]) + int(x.upper().split('+')[1])/7, 2) if '+' in x.upper()
    else round(float(x.upper().replace('W', '')), 2)
)
data = data.dropna(subset=['孕周_小数', '在参考基因组上比对的比例', '原始读段数'])
gestation_filtered = data[data['孕周_小数'].between(10, 25)]
data = gestation_filtered

data = data[(data['孕妇 BMI'] >= 18.5) & (data['孕妇 BMI'] <= 50)]
data = data[(data['年龄'] >= 18) & (data['年龄'] <= 55)]
```

```

data = data[(data['GC 含量'] >= 0.35) & (data['GC 含量'] <= 0.6)]# GC 含量的值限制条件为
0.35-0.6
data = data[(data['孕周_小数'] >= 12) & (data['孕周_小数'] <= 20)]# 孕周为 12-20 周

filtered_data.to_csv('Y 染色体数据 1.csv', index=False, encoding='gbk')
print(f" 原始数据 :{len(data)} 行 , 最终保留 :{len(filtered_data)} 行 , 共过滤 :{len(data)-
len(filtered_data)}行")

```

问题一：

```

import pandas as pd
import matplotlib.pyplot as plt
plt.rcParams['font.sans-serif']=['SimHei']
plt.rcParams['axes.unicode_minus']=False
import statsmodels.api as sm
df = pd.read_csv("Y 染色体数据 1.csv",encoding='gbk')

from scipy.stats import pearsonr, spearmanr

df = pd.read_csv('Y 染色体数据 1.csv',encoding='gbk')
data = df[['Y 染色体浓度', '孕妇 BMI', '孕周_小数']].dropna()

y = data['Y 染色体浓度']
bmi = data['孕妇 BMI']
week = data['孕周_小数']

# Pearson 相关系数
pearson_bmi, p_bmi = pearsonr(y, bmi)
pearson_week, p_week = pearsonr(y, week)

# Spearman 相关系数
spearman_bmi, sp_bmi = spearmanr(y, bmi)
spearman_week, sp_week = spearmanr(y, week)

print(" 相关系数运行得到的结果:")
print(f"Y 染色体浓度 vs 孕妇 BMI:")
print(f"  Pearson: {pearson_bmi:.3f} (p={p_bmi:.3f})")
print(f"  Spearman: {spearman_bmi:.3f} (p={sp_bmi:.3f})")
print(f"Y 染色体浓度 vs 孕周:")
print(f"  Pearson: {pearson_weeks:.3f} (p={p_weeks:.3f})")
print(f"  Spearman: {spearman_weeks:.3f} (p={sp_weeks:.3f})")
y = df['Y 染色体浓度']
X = df[['孕周_小数', '孕妇 BMI', '年龄']].copy()

```

```

X['孕周^2'] = X['孕周_小数'] ** 2
X['BMI^2'] = X['孕妇 BMI'] ** 2
X['孕周×BMI'] = X['孕周_小数'] * X['孕妇 BMI']#构建多元交互项

```

```

X = sm.add_constant(X)
model = sm.OLS(y, X).fit()
print(model.summary())

```

男胎热力图：

```

from sklearn.preprocessing import StandardScaler
import os
import matplotlib.pyplot as plt
plt.rcParams['font.sans-serif'] = ['SimHei']
plt.rcParams['axes.unicode_minus'] = False
data = pd.read_csv("男胎检测数据.csv", encoding='gbk').dropna()

columns_to_plot = [
    '13 号染色体的 Z 值', '18 号染色体的 Z 值', '21 号染色体的 Z 值',
    'X 染色体的 Z 值', 'Y 染色体的 Z 值',
    'Y 染色体浓度', 'X 染色体浓度',
    'GC 含量', '被过滤掉读段数的比例'
]

data_to_plot = df[columns_to_plot]

# 分组聚合后标准化，可以作出准确的热力图
group_size = 10
group_indices = [i // group_size for i in range(len(data_to_plot))]
grouped_data = data_to_plot.groupby(group_indices).mean()

group_labels = [f'样本组{i+1}' for i in grouped_data.index]
grouped_data.index = group_labels

scaler = StandardScaler()
scaled_data = scaler.fit_transform(grouped_data)
scaled_grouped_df = pd.DataFrame(scaled_data, index=group_labels,
columns=columns_to_plot)

plt.figure(figsize=(14, 8))
sns.heatmap(
    scaled_grouped_df.T,
    cmap='RdBu_r',
    vmin=-3, vmax=3,

```

```

        center=0,
        cbar_kws={'label': 'Z-score'},
        linewidths=0
    )

plt.title('男胎检测数据热力图 (分组聚合后)', fontsize=16, pad=20)
plt.xlabel('样本组', fontsize=12)
plt.ylabel('检测指标', fontsize=12)
plt.yticks(rotation=0)

plt.tight_layout()

```

各指标柱状分布图

```

df['年龄'].plot(kind='hist', ax=axes[0, 0], bins=20, edgecolor='black')
axes[0, 0].set_title('年龄分布柱形图')
axes[0, 0].set_xlabel('年龄')
axes[0, 0].set_ylabel('频数')

df['孕妇 BMI'].plot(kind='hist', ax=axes[0, 1], bins=20, edgecolor='black')
axes[0, 1].set_title('孕妇 BMI 分布柱形图')
axes[0, 1].set_xlabel('孕妇 BMI')
axes[0, 1].set_ylabel('频数')

df['Y 染色体浓度'].plot(kind='hist', ax=axes[1, 0], bins=20, edgecolor='black')
axes[1, 0].set_title('Y 染色体浓度分布柱形图')
axes[1, 0].set_xlabel('Y 染色体浓度')
axes[1, 0].set_ylabel('频数')

df['检测孕周_数值'].plot(kind='hist', ax=axes[1, 1], bins=20, edgecolor='black')
axes[1, 1].set_title('检测孕周分布柱形图')
axes[1, 1].set_xlabel('检测孕周')
axes[1, 1].set_ylabel('频数')

plt.tight_layout()
plt.show()

```

孕周与 BMI 的三维交互图：

```

data = pd.read_csv("Y 染色体数据.csv", encoding='gbk').dropna()

X = data[['孕周_小数', '孕妇 BMI']]
y = data['Y 染色体浓度']

```

```

poly = PolynomialFeatures(degree=2)
X_poly = poly.fit_transform(X)

model = LinearRegression()
model.fit(X_poly, y)# 训练模型

x1 = np.linspace(X['孕周_小数'].min(), X['孕周_小数'].max(), 100)
x2 = np.linspace(X['孕妇 BMI'].min(), X['孕妇 BMI'].max(), 100)
X1, X2 = np.meshgrid(x1, x2)

X_grid = np.column_stack([X1.ravel(), X2.ravel()])
X_grid_poly = poly.transform(X_grid)# 转换多项式特征

y_grid = model.predict(X_grid_poly).reshape(X1.shape)

critical_region = (X2 >= 36) & (X1 < 12)
critical_region_y = y_grid[critical_region]
critical_region_mean = np.mean(critical_region_y) if critical_region_y.size > 0 else 0

# 绘制三维曲面图
fig = plt.figure(figsize=(10, 8))
ax = fig.add_subplot(111, projection='3d')
surf = ax.plot_surface(X1, X2, y_grid, cmap='viridis', edgecolor='none')
ax.set_xlabel('孕周')
ax.set_ylabel('BMI')
ax.set_zlabel('Y 染色体浓度')
ax.set_title('孕周 × BMI 交互效应三维曲面图')

plt.show()
plt.savefig('孕周 × BMI 交互效应三维曲面图.png')
plt.close()

```

问题二：

```

import pandas as pd
import numpy as np
df = pd.read_csv("Y 染色体数据 1.csv", encoding="gbk")
#进行变量名的命名与参数设置
MIN_GEST = 10.0
MAX_GEST = 25.0
Y_TARGET = 0.04

```

```

AVG_AGE = 30.0
ALPHA = 0.95
BMI_MIN, BMI_MAX = 20.0, 42.0
def calc_y(gest, bmi, age=AVG_AGE):
    y = (-0.3595
        + 0.0279 * gest
        + 0.0169 * bmi
        - 0.0009 * age
        - 0.0009 * gest**2
        - 0.0003 * bmi**2)
    return max(y, 0)    # 通过问题一得到的回归方程

def get_group_optimal_t(group_bmis):
    if len(group_bmis) == 0:
        return MAX_GEST

    low, high = MIN_GEST, MAX_GEST
    best_gest = MAX_GEST

    epsilon = 0.1

    while high - low > epsilon:
        mid = (low + high) / 2
        qualified_count = sum(calc_y(mid, bmi) >= Y_TARGET for bmi in group_bmis)
        qualified_rate = qualified_count / len(group_bmis)

        if qualified_rate >= ALPHA:
            best_gest = mid
            high = mid
        else:
            low = mid

    return round(best_gest, 1)

def risk_function(t):
    if t <= 12:
        return 1.0
    elif 13 <= t <= 27:
        return 5.0
    else:
        return 20.0    #定义风险函数，设置早、中、晚期分别发现为低、高、极高风险（即 1.0, 5.0, 20.0

def calculate_total_risk(groups, all_bmis_count):

```

```

total_risk = 0.0
for group_bmis in groups:
    if len(group_bmis) == 0:
        continue

    t_k = get_group_optimal_t(group_bmis)# 最优检测时点
    r_k = risk_function(t_k) # 风险值
    weight_k = len(group_bmis) / all_bmis_count
    total_risk += r_k * weight_k# 将以上累加为总风险
return total_risk#定义为目标函数
valid_bmis = df["孕妇 BMI"].values
total_sample_count = len(valid_bmis)

K_candidates = [1,2,3,4,5,6]#计划候选分组数

best_total_risk = float("inf")
best_K = None
best_groups_info = None

for K in K_candidates:
    print(f"\n 分组数 K={K}的方案 ")
    splits = np.linspace(BMI_MIN, BMI_MAX, K + 1)[1:-1]
    splits = np.round(splits, 1) #
    print(f"当前 K={K}的分割点: {splits.tolist()}")

    groups_bmis = []
    prev_bmi = BMI_MIN # 按分割点将 BMI 数据划分为 K 组, 并储存数据列表, 由
    起始值开始

    for split in splits:
        group = valid_bmis[(valid_bmis >= prev_bmi) & (valid_bmis < split)]
        groups_bmis.append(group)
        prev_bmi = split # 遍历所选择区间, 开始下一组

    last_group = valid_bmis[valid_bmis >= prev_bmi]
    groups_bmis.append(last_group)#完成最后一组

    current_total_risk = calculate_total_risk(groups_bmis, total_sample_count)
    print(f"K={K}的总体风险: {current_total_risk:.4f}",

    groups_info = []
    for i, group_bmis in enumerate(groups_bmis, 1):

```

```

t_k = get_group_optimal_t(group_bmis)
r_k = risk_function(t_k)
weight_k = len(group_bmis) / total_sample_count
groups_info.append({
    "组号": i,
    "BMI 范围": [round(splits[i-2],1) if i>1 else BMI_MIN,
                 round(splits[i-1],1) if i<K else BMI_MAX],
    "样本数": len(group_bmis),
    "最优检测时点": t_k,
    "风险值": r_k,
    "权重": round(weight_k, 3)
})

if current_total_risk < best_total_risk:
    best_total_risk = current_total_risk
    best_K = K
    best_groups_info = groups_info#因为此次风险更小所以更新为新方案

```

问题三：

#摘要 1 评估模型

```
import lightgbm as lgb
```

```
df = pd.read_csv("Y 染色体数据 1.csv",encoding='gbk')
```

```
features = ["孕周_小数", "身高", "体重", "年龄"]
```

```
target = "Y 染色体浓度"
```

```

X_train, X_test, y_train, y_test = train_test_split(
    df[features], df[target], test_size=0.2, random_state=42
)# 训练集和测试集作出划分

```

```

model = lgb.LGBMRegressor(
    n_estimators=100,
    learning_rate=0.05,
    max_depth=5,
    random_state=30
)# 构建 LightGBM 回归模型

```

```

model.fit(X_train, y_train)# 训练模型
y_pred = model.predict(X_test)

```

```

mae = mean_absolute_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)
print(f'MAE: {mae:.4f}, R²: {r2:.4f}')# 评估, 评估结果为 MAE: 0.0227, R²: 0.1405

```

#摘要 2 构建决策树

```
from sklearn.tree import export_text, DecisionTreeRegressor, plot_tree
df['BMI'] = df['体重'] / (df['身高'] / 100) ** 2  ## 计算 BMI 身高转换为 m
```

```
features = ['BMI', '身高', '年龄']
X = df[features]
y = df['孕周_小数']
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)# 划分为
训练测试集
```

```
tree_model = DecisionTreeRegressor(
    max_depth=4,
    min_samples_split=20,
    min_samples_leaf=10,
    random_state=42
)# 构建回归决策树
```

```
tree_model.fit(X_train, y_train)
y_pred = tree_model.predict(X_test)
mse = mean_squared_error(y_test, y_pred)
print(f"模型 MSE: {mse:.2f}")# 模型的预测和评估
```

```
tree_rules = export_text(tree_model, feature_names=features)
print("决策树规则:")
print(tree_rules)
df['group'] = tree_model.apply(X)
```

#摘要 3 分析每个风险影响就接触最佳参数

```
def visualize_optimization_results(results_df):
    fig, axes = plt.subplots(2, 2, figsize=(15, 12))

    #根据各个变量对于风险的影响作出，求解出最佳参数
    depth_risk = results_df.groupby('max_depth')['total_risk'].mean()
    axes[0,0].plot(depth_risk.index, depth_risk.values, 'o-', linewidth=2)
    axes[0,0].set_xlabel('决策树深度')
    axes[0,0].set_ylabel('平均总体风险')
    axes[0,0].set_title('树深度对总体风险的影响')
    axes[0,0].grid(True, alpha=0.3) # 树深度 vs 风险
```

```

group_risk = results_df.groupby('n_groups')['total_risk'].mean()
axes[0,1].plot(group_risk.index, group_risk.values, 's-', linewidth=2, color='orange')
axes[0,1].set_xlabel('分组数量')
axes[0,1].set_ylabel('平均总体风险')
axes[0,1].set_title('分组数量对总体风险的影响')
axes[0,1].grid(True, alpha=0.3)# 分组数 vs 风险

gamma_risk = results_df.groupby('gamma')['total_risk'].mean()
axes[1,0].plot(gamma_risk.index, gamma_risk.values, '^-', linewidth=2, color='green')
axes[1,0].set_xlabel('风险惩罚系数  $\gamma$ ')
axes[1,0].set_ylabel('平均总体风险')
axes[1,0].set_title('风险惩罚系数对总体风险的影响')
axes[1,0].grid(True, alpha=0.3)#  $\gamma$  参数 vs 风险

#摘要 4 匹配风险函数，求出最优解
group_means = df.groupby('group')['孕周_小数'].mean().sort_values(ascending=False)#每组
平均达标孕周

for group_id, avg_weeks in group_means.items():
    group_data = df[df['group'] == group_id]
    print(f"组{group_id}: 平均{avg_weeks:.1f}周达标, 样本数: {len(group_data)}")

total_groups = len(group_means)
low_risk_threshold = total_groups // 3
medium_risk_threshold = 2 * total_groups // 3

#分配风险等级
risk_groups = {}
for i, (group_id, avg_weeks) in enumerate(group_means.items()):
    if i < low_risk_threshold:
        risk_groups[group_id] = '低风险'
    elif i < medium_risk_threshold:
        risk_groups[group_id] = '中风险'
    else:
        risk_groups[group_id] = '高风险'

df['风险等级'] = df['group'].map(risk_groups)#增加风险等级列

risk_stats = df.groupby('风险等级').agg({
    '孕周_小数': ['mean', 'std', 'min', 'max', 'count'],
    'BMI': 'mean',

```

```

        '身高': 'mean',
        '年龄': 'mean'
    })# 统计各组的最佳检测时点

for risk_level in ['低风险', '中风险', '高风险']:
    risk_data = df[df['风险等级'] == risk_level]

    avg_weeks = risk_data['孕周_小数'].mean()
    recommended_week = max(12, avg_weeks - 1.5) # 计算最佳检测时点, 最后去掉 1-2 周, 不低于 12 周

```

女胎数据清洗:

```

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.feature_selection import RFE, SelectFromModel
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import (
    accuracy_score,
    precision_score,
    recall_score,
    f1_score,
    roc_auc_score,
    classification_report,
    roc_curve
)

from imblearn.over_sampling import SMOTE
import warnings
warnings.filterwarnings('ignore')
df = pd.read_csv('女胎检测数据.csv', encoding='utf-8')
# 转换孕周为数值格式 (如男胎)
data['孕周_小数'] = data['检测孕周'].apply(
    lambda x: round(int(x.upper().split('W')[0]) + int(x.upper().split('+')[1])/7, 2) if '+' in x.upper()
    else round(float(x.upper().replace('W', '')), 2)
)

df['is_abnormal'] = df['染色体的非整倍体'].apply(
    lambda x: 1 if isinstance(x, str) and any(ab in x for ab in ['T21', 'T18', 'T13']) else 0
)#创建目标变量为 is_abnormal,设置异常值为 1, 正常值为 0

```

```

unnamed_cols = [col for col in df.columns if 'Unnamed' in col]
cols_to_drop = [
    '序号', '孕妇代码', '末次月经', 'IVF 妊娠', '检测日期',
    '检测抽血次数', '检测孕周', '染色体的非整倍体', '胎儿是否健康'
] + unnamed_cols
df.drop(columns=cols_to_drop, inplace=True)#移除不需要的列和空值
initial_rows = df.shape[0]
df = df[(df['孕妇 BMI'] >= 15) & (df['孕妇 BMI'] <= 60)]#移除 bmi 异常值
for col in df.select_dtypes(include=np.number).columns:
    if df[col].isnull().any():
        median_val = df[col].median()
        df[col].fillna(median_val, inplace=True)#用中位数填充缺失值

X = df.drop('is_abnormal', axis=1)
y = df['is_abnormal']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42, stratify=y
)#区分测试集和训练集

X_train['怀孕次数'] = X_train['怀孕次数'].replace('≥3', '3', regex=True)
X_train['怀孕次数'] = X_train['怀孕次数'].astype(float)
X_test['怀孕次数'] = X_test['怀孕次数'].replace('≥3', '3', regex=True)
X_test['怀孕次数'] = X_test['怀孕次数'].astype(float) # 替换出错的符号

set_lgb = set(lgb_selected_features)
set_lr = set(lr_selected_features)
set_rfe = set(rfe_selected_features)
final_selected_features = list(set_lgb & set_lr & set_rfe) #完成三种方法后取交集

accuracy = accuracy_score(y_test, y_pred)
precision = precision_score(y_test, y_pred)
recall = recall_score(y_test, y_pred)
f1 = f1_score(y_test, y_pred)
auc = roc_auc_score(y_test, y_pred_proba) # 计算各项指标

print(f"准确率 (Accuracy): {accuracy:.4f}")
print(f"精确率 (Precision): {precision:.4f}")
print(f"召回率 (Recall): {recall:.4f}")
print(f"F1 分数 (F1-Score): {f1:.4f}")
print(f"AUC (Area Under ROC Curve): {auc:.4f}\n")

```

生成可视化 ROC 图：

```

fpr, tpr, thresholds = roc_curve(y_test, y_pred_proba)

plt.figure(figsize=(8, 6))
plt.plot(fpr, tpr, color='darkorange', lw=2, label=f'ROC curve (area = {auc:.2f})')
plt.plot([0, 1], [0, 1], color='navy', lw=2, linestyle='--')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.rcParams['font.sans-serif'] = ['SimHei']
plt.rcParams['axes.unicode_minus'] = False
plt.xlabel('假阳性率 (False Positive Rate)')
plt.ylabel('真阳性率 (True Positive Rate)')
plt.title('接收者操作特征曲线 (ROC Curve)')
plt.legend(loc="lower right")
plt.grid(True)
plt.show()

```